


Approximations de rang faible régularisées

Approximations de rang faible régularisées

Théorie, algorithmes et applications

Jérémy Cohen, CR CNRS, CREATIS

30 Juin 2026 TODO ajout de refs externes



Jury

- Sophie Achard (DR CNRS, LJK, Grenoble) — examinatrice
- Sébastien Bourguignon (Professeur, LS2N, Nantes) — rapporteur
- Cédric Févotte (DR CNRS, IRIT, Toulouse) — rapporteur
- Simon Masnou (Professeur, ICJ, Lyon) — examinateur
- Joseph Salmon (DR Inria, Université de Montpellier) — rapporteur

CV

Encadrement

- 4 PhD encadrés (2 en cours)
- 5 PhD suivis (1 en cours)
- 2 postdocs (1 en cours)
- 1 ingénieur
- 12 master (M1 et M2)

Services

- Membre élu CoNRS 03
- Organisation sessions spéciales
- Organisation journées scientifiques

Publications

Depuis 2020,

- ~10 R.I. (SIMODS, TMLR...)
- ~15 C.I. (EUSIPCO...)

Valorisation

- Open source (Tensorly)
- Projets (ANR JCJC)
- Vulgarisation
 - Podcasts
 - Conf. grand public




1. Introduction à l'approximation de faible rang régularisée

La réduction de dimension


- En apprentissage machine, deux objectifs reviennent souvent :
 - extraire de l'information utile de données ;
 - compresser les données.
- Ces deux objectifs se rejoignent souvent : un bon résumé des données conserve l'information utile.
- C'est le rôle de la **réduction de dimension**.

Exemple: la vision par l'oeil humain en RGB (simplifié)



source: <http://hyperphysics.phy-astr.gsu.edu/>


Réduction de dimension et images RGB



Approximation de rang faible (LRA) ?

- Un modèle de rang faible est une réduction de dimension pour des tableaux (matrices, tenseurs)
 - $W \in \mathbb{R}^{n_1 \times r}$ et $H \in \mathbb{R}^{n_2 \times r}$ sont des **matrices inconnues**.
 - Le nombre de paramètres est réduit de $n_1 n_2$ à $r(n_1 + n_2)$.
- $$M \in \mathbb{R}^{n_1 \times n_2}, \quad M \approx WH^T$$

$$\underbrace{M}_{\text{données}} \in \mathbb{R}^{n_1 \times n_2}, \quad M \approx WH^T$$




Exemple d'approximation de rang faible d'une image hyperspectrale

Formulation variationnelle,
avec f une fonction de perte :

$$(W^*, H^*) = \arg \min_{W, H} f(M, WH^T)$$

- Problème non convexe, multi-bloc
- Solution directe avec la SVD

LRA, des applications en séparation de sources aveugle



Enjeu

Pouvoir donner un sens physique aux résultats du LRA.

- Imagerie spectrale
 - Biopsie optique pour chirurgie guidée par l'imagerie
 - Imagerie satellite pour la surveillance de l'environnement
 - Imagerie astronomique pour l'étude de l'univers
- Chimiométrie: analyse de composés chimiques
- Informatique musicale: séparation de sources musicales, transcription automatique

Pourquoi régulariser ?

- LRA n'est pas **identifiable**:

$$M = WH^T = (WA)(A^{-1}H^T), \quad \forall A \in \mathbb{R}^{r \times r} \text{ inversible.}$$

Il existe une infinité de solutions équivalentes, mais une seule (pour simplifier) nous intéresse: celle qui correspond à la réalité physique du problème.

- Solution: introduire des régularisations (rLRA)

$$\min_{W, H} f(M, WH^T) + g_W(W) + g_H(H).$$


- Les termes de régularisation peuvent imposer
 - la nonnégalité, $g_W(W) = 0$ si $W \geq 0$, $+\infty$ sinon,
 - la parcimonie, $g_W(W) = ||W||_1$,
 - ...

Important

Les régularisations changent drastiquement les propriétés du modèle !

Nonnégativité

- Dans beaucoup de problèmes de mélange, les quantités sont **additives** et **nonnégatives**.
- La nonnégativité devient alors une régularisation naturelle.
- Elle fournit des décompositions :
 - par parties,
 - physiquement interprétables.



LRA nonnégative

LRA + nonnégativité = **Nonnegative Matrix Factorization (NMF)**


$$\arg \min_{W \geq 0, H \geq 0} f(M, WH^T)$$

J'utiliserai l'anglicisme "nonnégatif" au lieu de "positif ou nul".


NMF, modèle géométrique

NMF in Frobenius norm


$$\arg \min_{W \geq 0, H \geq 0} \|M - WH^T\|_F^2$$




NMF, modèle géométrique et identifiabilité



2D embedding







NMF en imagerie hyperspectrale



crédits: S. Hariga, N. Ducros et L. Mahieu-Willame

NMF en imagerie hyperspectrale — résultats




Optimisation numérique et rLRA

- On estime souvent les paramètres W et H par un algorithme alterné.
- Un algorithme classique mais théorique: Alternating Nonnegative Least Squares (régularisés)

[Math Processing Error]

- De nombreux résultats de convergence existent pour ce type de procédures alternées [Bertsekas 1999, Grippo Scaife 2000, Razaviyan et al. 2013, Beck 2017...].
- De nombreux algorithmes existent pour résoudre chaque sous-problème.



rLRA: Défis scientifiques

Théorie

1. **Identifiabilité** : quand peut-on faire confiance aux résultats ?
2. **Caractérisation des solutions** : que produit réellement une régularisation ?
3. **Information auxiliaire** : comment intégrer dictionnaires, supervision, multimodalité ?
4. **Choix du rang** : combien de composantes utiliser ?

Optimisation numérique: comment calculer les LRA

Les rLRA sont **non convexes**, **multi-blocs**, **non lisses**. Les algorithmes dépendent fortement de la **fonction de perte f** .

1. **Rapidité des algorithmes**: avoir une bonne solution le plus rapidement possible.
2. **Flexibilité**: les algorithmes doivent pouvoir intégrer des contraintes et régularisations variées.

Le code, un aspect souvent négligé

Le progrès scientifique passe aussi par le **logiciel** et les **benchmarks** de qualité, et la **reproductibilité** des résultats.

2. Contributions aux rLRA: théorie, algorithmes et applications

Contributions scientifiques

Théorie

1. **Identifiabilité** : C. & Gillis (SIMODS 2019), C. et al. (LVA/ICA 2017)
2. **Caractérisation des solutions** : C. & Leplat (SIMODS 2025)
3. **Information auxiliaire** : C. & Gillis (IEEE TSP & TGRSL 2018), C. (Applied Mathematics and Statistics 2022), Kervazo et al. (EUSIPCO 2024)

Optimisation numérique: comment calculer les LRA

1. **Rapidité des algorithmes**: Nadisic et al. (ICASSP 2020), Pham et al. (TMLR 2026)
2. **Flexibilité**: Schenker et al. (IEEE JSTSP 2020), Roald et al. (SIMODS 2022)

Applications spécifiques


1. **Imagerie hyperspectrale microscopique** : Harriga et al. (EUSIPCO 2024), Carreda et al. (Biomedical Optics Express 2023)
2. **Informatique musicale**: Marmoret et al. (ISMIR 2020), Wu et al. (SMC 2022), Marmoret et al. (TISMIR 2023)

Zoom sur une contribution: régularisation implicite et rLRA

Un problème mal compris avec rLRA

Pour rendre la NMF “plus identifiable”, on considère souvent la NMF parcimonieuse

$$\arg \min_{W \geq 0, H \geq 0} \|M - WH^T\|_F^2 + \lambda \|W\|_1 + \lambda \|H\|_1.$$





Warning

Peu de résultats sont connus sur l'ensemble des solutions de ce problème, notamment si les régularisations ℓ_1 induisent vraiment de la parcimonie dans W et H .

Un autre problème: le marais de l'échelle

$$f(x_1, x_2) = (y - x_1 x_2)^2 + \lambda(x_1^2 + x_2^2).$$

```
1 from matplotlib import axes
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 # A barebone implementation of ALS
6 def ALS(y,x1,x2, lamb, itermax=200):
7     loss = [(y - x1*x2)**2 + lamb * (x1**2 + x2**2)]
8     x1_store = [x1]
9     x2_store = [x2]
10    for k in range(itermax):
11        x1 = x2*y/(x2**2+lamb)
12        x2 = x1*y/(x1**2+lamb)
13        loss.append((y - x1*x2)**2 + lamb*(x1**2 + x2**2))
14        x1_store.append(x1)
15        x2_store.append(x2)
16    return x1, x2, loss, x1_store, x2_store
17
18 # Problem setup
19 y = 1
20 lamb = 0.001
21
22 # Initialization
23 x1 = 0.2
24 x2 = 5
25
26 # Run ALS
27 x1, x2, loss, x1store, x2store = ALS(y, x1, x2, lamb)
```



L'ambiguïté d'échelle induit une régularisation implicite

La NMF parcimonieuse

$$\arg \min_{W \geq 0, H \geq 0} \|M - WH^T\|_F^2 + \lambda_W \|W\|_1 + \lambda_H \|H\|_1.$$

a des solutions équivalentes, à échelle près, au problème suivant:


$$\arg \min_{W \geq 0, H \geq 0} \|M - WH^T\|_F^2 + 2\sqrt{\lambda_W \lambda_H} \sum_{q=1}^r \sqrt{\|W[:, q]H[:, q]^T\|_1}.$$

Conséquences

- La double régularisation ℓ_1 induit une parcimonie de groupe sur les sources.
- Les paramètres λ_W et λ_H ne sont pas indépendants : il faut les choisir conjointement.
- Les solutions sont équilibrées: $\|W[:, q]\|_1 = \|H[:, q]\|_1$ si $\lambda_W = \lambda_H$.

Equilibrage des solutions pour sortir des marais

On équilibre les valeurs initiales d'un algorithme classique pour la NMF (tensorielle).



- problème NCPD
- régularisation ℓ_2
- dimensions [10,11,12]
- rang réel 3
- rang estimé 6

Remarques sur ce travail

On montre en fait des résultats plus généraux, qui tiennent pour

- La plupart des fonctions de coût f usuelles (KL-divergence, Frobenius, etc.).
- Toute régularisation homogène de degré arbitraire.
- Des décompositions de rang faible matricielles et tensorielles (NMF, CPD, Tucker, etc.).

Proposition

Les solutions du problème explicite

$$\arg \min_{\forall i \leq n, X_i \in \mathbb{R}^{m_i \times r}} f(\{X_i\}_{i \leq n}) + \sum_{i=1}^n \mu_i \sum_{q=1}^r g_i(X_i[:, q])$$

sont essentiellement identiques à celles du problème implicite


[Math Processing Error]

où p_i est le degré d'homogénéité de g_i et $\tilde{\mu}$ dépend explicitement de μ_i .

Zoom sur une contribution: Transcription automatique de musique

avec Axel Marmoret (IMT Atlantique, ancien doctorant) et Haoran Wu (Syneron Technology (Chine), ancien stagiaire de master)


Transcription automatique ?



- Peut se faire “à la main”.
- L’état de l’art actuel est réalisé par des réseaux de neurones entraînés de façon supervisée.
- Notre travail est de montrer que l’on peut atteindre des performances comparables avec des méthodes faiblement supervisées, basées sur la NMF.

Notes isolées, spectrogramme et NMF



Analyse temps-fréquence d'un la (milieu de clavier) joué au piano.




NMF-KL d'un extrait



NMF-KL d'un extrait simple (vert)




NMF-KL d'un extrait complexe (rouge)



Une brique essentielle: la NMF convolutive


$$M = \sum_{q=1}^r \sum_{\tau=0}^{T-1} W[f, \tau, q] H[q, t - \tau].$$

- Les templates fréquentiels dépendent aussi du temps (modélisation de l'attaque et de la décroissance des notes).
- Proposé par [Smaragdis, 2006], algorithmne efficace par [Fagot et al., 2019].



Notre contribution: NMF convolutive semi-supervisée

Apprendre les templates fréquentiels sur des notes isolées (dataset MAPS) par des CNMS de rang 1.



Des résultats prometteurs...

Seuillage	Méthode	τ	EN1	EN2	AkB1	AkB2	AkC	AkS	Sp	St
global	CNMF	5	78	70	88	75	83	80	81	75
		10	85	77	93	87	91	88	89	84
		20	83	76	94	87	92	87	90	86
global	AD*	—	81	68	66	71	60	67	64	67
song	CNMF	5	82	74	90	80	87	84	86	81
		10	88	80	95	90	94	90	93	89
		20	85	78	95	90	94	89	92	89
song	AD*	—	82	69	68	73	61	69	66	70
—	DNN	—	89	77	98	95	98	87	97	95

Tableau : Performances en F mesure de CNMF, AD et du réseau profond de ByteDance. Tolérance de 50 ms. AD: [Cheng et al. 2016], DNN par ByteDance [Kong et al. 2020].

...mais des problèmes pour généraliser

Pianos	EN2	AkB1	AkB2	AkS	Sp	St
Entrainement sur AkC	74	77	77	70	74	77
Entrainement sur EN1	76	67	68	69	67	69

Tableau : Scores de transcription pour CNMF, avec un décalage entre les données d'apprentissage et de test.

Retour aux contributions scientifiques

Théorie

1. **Identifiabilité** : C. & Gillis (SIMODS 2019), C. et al. (LVA/ICA 2017)
2. **Caractérisation des solutions** : C. & Leplat (SIMODS 2025)
3. **Information auxiliaire** : C. & Gillis (IEEE TSP & TGRSL 2018), C. (Applied Mathematics and Statistics 2022), Kervazo et al. (EUSIPCO 2024)

Optimisation numérique: comment calculer les LRA

1. **Rapidité des algorithmes**: Nadisic et al. (ICASSP 2020), Pham et al. (TMLR 2026)
2. **Flexibilité**: Schenker et al. (IEEE JSTSP 2020), Roald et al. (SIMODS 2022)

Applications spécifiques

1. **Imagerie hyperspectrale microscopique** : Harriga et al. (EUSIPCO 2024), Carreda et al. (Biomedical Optics Express 2023)
2. **Informatique musicale**: Marmoret et al. (ISMIR 2020), Wu et al. (SMC 2022), Marmoret et al. (TISMIR 2023)

Perspectives de recherche

La divergence KL en traitement du signal

Pour un vecteur observé $y \in \mathbb{R}^d$ fixé, on pose *[Math Processing Error]*


- Fonction de coût pour les données issues du comptage
 - Comptage de photon (tomographie, caméra médicales, astronomie...)
 - Comptage de mots dans des textes (topic modeling)
- Propriétés intéressantes
 - Adaptés aux données à fortes dynamiques (spectrogrammes)
 - Invariant par changement d'échelle

Important

Ne se réduit pas à une distance ℓ_2 si on compte peu d'objets, ou si les données sont très creuses.

Géométrie de la divergence de KL en dimension 1

[Math Processing Error]



Important

La divergence KL est une fonction difficile à optimiser:

- son gradient est non lisse (Lipschitz).
- elle n'est pas fortement convexe et pas coercive (si présence de zéros).

Pourquoi étudier l'optimisation de modèles rLRA + KL ?

- Les algorithmes de régression avec une fonction de perte KL sont souvent indisponibles ou peu performants.
 - Par exemple la régression TV avec une perte KL a été étudiée seulement récemment [Maxim et al. 2023]

$$\arg \min_{h \geq 0} \mathcal{D}_{KL}(m, Wh) + \lambda \|h\|_{TV}.$$


- Les recherches actuelles se concentrent sur des l'utilisation de divergence Bregman, sachant que $\mathcal{D}_{KL}$ est de gradient lisse dans la géométrie induite par l'entropie de Burg.
- l'état de l'art **non régularisé** est dominé par MLEM/MU et ses variantes [Lucy 1974, Dempster 1977].
[Math Processing Error]

Burg vs MLEM en régression KL

Hypothèse de travail

Il est possible de construire des algorithmes plus rapides que MLEM, et de les adapter pour des régularisations complexes.


- Descente miroir avec Burg et MLEM sont deux algorithmes de majoration-minimization. Avec Damien Lesens et Bora Ucar (LIP), nous sommes en train de montrer que
 - MLEM est toujours plus proche du coût que Burg
 - MLEM est la meilleure majorante séparable de KL.



Idées



- Proposer des approximations locales (gradient préconditionné, Newton)
- S'inspirer de littératures voisines (points intérieurs, programmation linéaire)

Programme de recherche



Perspective 1 — benchmark et logiciel

- Pour NN-KL et NMF-KL, il manque encore une culture du **benchmark**.
- Une priorité est donc de construire :
 - un benchmark reproductible,
 - une liste d'algorithmes/implémentations de référence,
 - des jeux de données ouverts pour effectuer les évaluations,
 - un article de survey sur NN-KL et NMF-KL.



Perspective 2 — nouveaux outils d'optimisation

- NN-KL, des directions prometteuses :
 1. des approximations locales d'ordre deux plus serrés.
 2. l'exploitation du lien avec la **programmation linéaire**, surtout en données creuses.
- NMF-KL: explorer également les algorithmes non-alternés [Fagot et al. 2019]
- L'objectif de long terme : des méthodes à la fois **rapides, robustes et principalement fondées**.

En collaboration avec Mai Quyen Pham (IMT Atlantique, Brest) et Damien Lesens et Bora Ucar (LIP, Lyon)

Perspective 3 — Problèmes inverses en imagerie computationnelle

- Terrain d'application immédiat : **imagerie spectrale single-pixel**.
- Question méthodologique centrale : **quand faut-il vraiment une méthode dédiée KL ?**
 - en fonction du modèle d'acquisition
 - en fonction du niveau de bruit Poisson vs Gaussien


Je souhaite explorer notamment les résultats autour des transformations de réduction de variance (type [Anscombe, 1948]).

- Développer des outils basés apprentissage profond (Plug and Play), en lien avec la suite de la thèse de Séréna Hariga.
 - Thèse de Guilhem Dupuis à partir de octobre 2026 avec Valentin Debarnot.

Collaborations: en local à CREATIS (Nicolas Ducros, Voichita Maxim, Elie Bretin, Valentin Debarnot...) et à l'international.

Perspective 4 - Transcription automatique avec NMF-KL et apprentissage profond

1. Utiliser un algorithme déroulé pour entraîner une NMF-KL convolutive.
2. Se baser sur les travaux de Magenta pour proposer un modèle hybride non-supervisé [Engel et al. 2020].



Conclusion

L'avenir des rLRA ?

+

- Des méthodes non-supervisés interprétables.
- Des garanties théoriques assez bien établies.
- Une modélisation physique au coeur des modèles.
- L'intérêt scientifique du travail sur l'optimisation numérique.

—

color bullets?

- Les performances état de l'art sont obtenues par des méthodes non-interprétables (réseaux profonds).
- Les méthodes non-supervisées sont souvent trop lentes pour être utilisées dans des applications temps réel.

Pour l'avenir, les rLRA pourront

- être utilisés comme **briques de construction** dans des modèles hybrides, combinant interprétabilité et performance.
- servir de baselines pour l'évaluations de modèles boîte noire.

Merci pour votre attention

Résumé des contributions scientifiques

Théorie

1. **Identifiabilité** : C. & Gillis (SIMODS 2019), C. et al. (LVA/ICA 2017)
2. **Caractérisation des solutions** : C. & Leplat (SIMODS 2025)
3. **Information auxiliaire** : C. & Gillis (IEEE TSP & TGRSL 2018), C. (Applied Mathematics and Statistics 2022), Kervazo et al. (EUSIPCO 2024)

Optimisation numérique: comment calculer les LRA

1. **Rapidité des algorithmes**: Nadisic et al. (ICASSP 2020), Pham et al. (TMLR 2026)
2. **Flexibilité**: Schenker et al. (IEEE JSTSP 2020), Roald et al. (SIMODS 2022)


Applications spécifiques

1. **Imagerie hyperspectrale microscopique** : Harriga et al. (EUSIPCO 2024), Carreda et al. (Biomedical Optics Express 2023)
2. **Informatique musicale**: Marmoret et al. (ISMIR 2020), Wu et al. (SMC 2022), Marmoret et al. (TISMIR 2023)

Backup

KL-div 2D

Courbes de niveau de la divergence de KL — le minimum est atteint en $x = y$



Autres travaux (backup slides?)

- Parler rapidement du principe de DLRA
- L0

suite

- Deep Unrolling
- Accélération
- Coupled decomposition

Applis

- HSI single pixel
- Structure estimation
- Brain imaging