


Approximations de rang faible régularisées

Approximations de rang faible régularisées

Théorie, algorithmes et applications

Jérémy Cohen, CR CNRS, CREATIS

30 Juin 2026



Jury

- Sophie Achard (*DR CNRS, LJK, Grenoble*) — examinatrice
- Sébastien Bourguignon (*Professeur, LS2N, Nantes*) — rapporteur
- Cédric Févotte (*DR CNRS, IRIT, Toulouse*) — rapporteur
- Simon Masnou (*Professeur, ICJ, Lyon*) — examinateur
- Joseph Salmon (*DR Inria, Université de Montpellier*) — rapporteur

CV

Encadrement

- 4 PhD encadrés (2 en cours)
- 5 PhD suivis (1 en cours)
- 2 postdocs (1 en cours)
- 1 ingénieur
- 12 master (M1 et M2)

Services

- Membre élu CoNRS 03
- Organisation sessions spéciales
- Organisation journées scientifiques

Publications

Depuis 2020,

- ~10 R.I. (SIMODS, TMLR...)
- ~15 C.I. (EUSIPCO...)

Valorisation

- Open source (Tensorly)
- Projets (ANR JCJC)
- Vulgarisation
 - Podcasts
 - Conf. grand public




1. Introduction aux approximations de rang faible régularisées

La réduction de dimension

- La **réduction de dimension** cherche à
 - extraire de l'information utile de données;
 - compresser des données.
- Ces deux objectifs se rejoignent souvent : un bon résumé des données conserve l'information utile.


Exemple: la perception des couleurs par l'oeil humain



Approximation de rang faible (Low Rank Approximation, LRA)

- Un modèle de rang faible est une réduction de dimension pour des tableaux (matrices, tenseurs)


$$\underbrace{M}_{\text{données}} \in \mathbb{R}^{n_1 \times n_2}, \quad M \approx WH^T$$



- $W \in \mathbb{R}^{n_1 \times r}$ et $H \in \mathbb{R}^{n_2 \times r}$ sont des **matrices inconnues**.
- Le nombre de paramètres est réduit de $n_1 n_2$ à $r(n_1 + n_2)$ avec $r \ll \min(n_1, n_2)$.
- Formulation variationnelle, avec f une fonction de perte :

$$(W^*, H^*) = \arg \min_{W, H} f(M, WH^T)$$

LRA, des applications en séparation de sources aveugle




- Imagerie spectrale
 - Biopsie optique pour chirurgie guidée par l'imagerie
 - Imagerie satellite pour la surveillance de l'environnement
 - Imagerie astronomique pour l'étude de l'univers
- Chimiométrie: analyse de composés chimiques
- Informatique musicale: séparation de sources musicales, transcription automatique

Enjeu

Pouvoir donner un sens physique aux résultats du LRA.

LRA en imagerie hyperspectrale, principe

$$M = WH^T$$



Exemple d'approximation de rang faible d'une image hyperspectrale

Pourquoi régulariser ?

- LRA n'est pas identifiable:

$$M = WH^T = (WA)(A^{-1}H^T), \quad \forall A \in \mathbb{R}^{r \times r} \text{ inversible.}$$

Il existe une infinité de solutions équivalentes, mais une seule (pour simplifier) nous intéresse: celle qui correspond à la réalité physique du problème.

- Pour fixer les ambiguïtés, introduire des régularisations (rLRA)

$$\min_{W, H} f(M, WH^T) + g_W(W) + g_H(H).$$

- Les termes de régularisation peuvent imposer
 - la **nonnégativité**, $g_W(W) = 0$ si $W \geq 0$, $+\infty$ sinon,
 - la parcimonie, $g_W(W) = ||W||_1$,
 - ...


Important

Les régularisations changent drastiquement les propriétés du modèle !

J'utiliserai l'anglicisme “nonnégatif” au lieu de “positif ou nul”.

Nonnégativité

- Dans beaucoup de problèmes de mélange, les quantités sont **additives** et **nonnégatives**.
- La nonnégativité devient alors une régularisation naturelle.
- Elle fournit des décompositions :
 - par parties,
 - physiquement interprétables.




LRA nonnégative

LRA + nonnégativité = **Nonnegative Matrix Factorization (NMF)**


$$\arg \min_{W \geq 0, H \geq 0} f(M, WH^T)$$

[Paatero 1997, Lee & Seung 1999]

NMF, modèle géométrique et identifiabilité



2D embedding




Optimisation numérique et rLRA

- On estime souvent les paramètres W et H par un algorithme alterné.
- Un algorithme classique mais théorique: Alternating Nonnegative Least Squares (régularisés)

$$\begin{cases} W^{(k+1)} = \arg \min_{W \geq 0} f(M, W H^{(k)T}) + g_W(W) \\ H^{(k+1)} = \arg \min_{H \geq 0} f(M, W^{(k+1)} H^T) + g_H(H) \end{cases}$$

- De nombreux résultats de convergence existent pour ce type de procédures alternées [Bertsekas 1999, Grippo Scriandrone 2000, Razaviyan et al. 2013, Beck 2017...].
- De nombreux algorithmes existent pour résoudre chaque sous-problème.



rLRA: Défis scientifiques

Théorie

1. **Identifiabilité** : quand peut-on faire confiance aux résultats ?
2. **Caractérisation des solutions** : que produit réellement une régularisation ?
3. **Information auxiliaire** : comment intégrer dictionnaires, supervision, multimodalité ?
4. **Choix du rang** : combien de composantes utiliser ?

Optimisation numérique: comment calculer les LRA

Les rLRA sont **non convexes, multi-blocs, non lisses**. Les algorithmes dépendent fortement de la **fonction de perte f** .

1. **Rapidité des algorithmes**: avoir une bonne solution le plus rapidement possible.
2. **Flexibilité**: les algorithmes doivent pouvoir intégrer des contraintes et régularisations variées.

2. Contributions aux rLRA: théorie, algorithmes et applications

Contributions scientifiques

Théorie

1. **Identifiabilité** : C. & Gillis (SIMODS 2019), C. et al. (LVA/ICA 2017)
2. **Caractérisation des solutions** : C. & Leplat (SIMODS 2025)
3. **Information auxiliaire** : C. & Gillis (IEEE TSP & TGRSL 2018), C. (Applied Mathematics and Statistics 2022), Kervazo et al. (EUSIPCO 2024)

Optimisation numérique: comment calculer les LRA

1. **Rapidité des algorithmes**: Nadisic et al. (ICASSP 2020), Pham et al. (TMLR 2026)
2. **Flexibilité**: Schenker et al. (IEEE JSTSP 2020), Roald et al. (SIMODS 2022)

Applications spécifiques


1. **Imagerie hyperspectrale microscopique** : Harriga et al. (EUSIPCO 2024), Carreda et al. (Biomedical Optics Express 2023)
2. **Informatique musicale**: Marmoret et al. (ISMIR 2020), Wu et al. (SMC 2022), Marmoret et al. (TISMIR 2023)

Zoom sur une contribution: régularisation implicite et rLRA

Un problème mal compris avec rLRA

Pour rendre la NMF “plus identifiable”, on considère souvent la NMF parcimonieuse [Eggert Korner 2004, Papalexakis et al. 2013]

$$\arg \min_{W \geq 0, H \geq 0} \|M - WH^T\|_F^2 + \lambda \|W\|_1 + \lambda \|H\|_1.$$





Warning

Peu de résultats sont connus sur l'ensemble des solutions de ce problème, notamment si les régularisations ℓ_1 induisent vraiment de la parcimonie dans W et H .

Un autre problème: le marais de l'échelle

$$f(x_1, x_2) = (y - x_1 x_2)^2 + \lambda(x_1^2 + x_2^2).$$

```
1 from matplotlib import axes
2 import numpy as np
3 import matplotlib.pyplot as plt
4
5 # A barebone implementation of ALS
6 def ALS(y, x1, x2, lamb, itermax=200):
7     loss = [(y - x1*x2)**2 + lamb * (x1**2 + x2**2)]
8     x1_store = [x1]
9     x2_store = [x2]
10    for k in range(itermax):
11        x1 = x2*y/(x2**2+lamb)
12        x2 = x1*y/(x1**2+lamb)
13        loss.append((y - x1*x2)**2 + lamb*(x1**2 + x2**2))
14        x1_store.append(x1)
15        x2_store.append(x2)
16    return x1, x2, loss, x1_store, x2_store
17
18 # Problem setup
19 y = 1
20 lamb = 0.001
21
22 # Initialization
23 x1 = 0.2
24 x2 = 5
25
26 # Run ALS
27 x1, x2, loss, x1store, x2store = ALS(y, x1, x2, lamb)
```



L'ambiguïté d'échelle induit une régularisation implicite

La NMF parcimonieuse

$$\arg \min_{W \geq 0, H \geq 0} \|M - WH^T\|_F^2 + \lambda_W \|W\|_1 + \lambda_H \|H\|_1.$$

a les mêmes solutions, à échelle près, que le problème suivant:


$$\arg \min_{W \geq 0, H \geq 0} \|M - WH^T\|_F^2 + 2\sqrt{\lambda_W \lambda_H} \sum_{q=1}^r \sqrt{\|W[:, q]H[:, q]^T\|_1}.$$

Conséquences

- La double régularisation ℓ_1 induit une parcimonie de groupe sur les sources.
- Les paramètres λ_W et λ_H ne sont pas indépendants : il faut les choisir conjointement.
- Les solutions sont équilibrées: $\|W^*[:, q]\|_1 = \|H^*[:, q]\|_1$ si $\lambda_W = \lambda_H$.

Equilibrage des solutions pour sortir des marais

On équilibre les valeurs initiales d'un algorithme classique pour la NMF (tensorielle).



- problème NCPD
- régularisation ℓ_2
- dimensions [10,11,12]
- rang réel 3
- rang estimé 6

Remarques sur ce travail

On montre en fait des résultats plus généraux, qui tiennent pour

- La plupart des fonctions de coût f usuelles (KL-divergence, Frobenius, etc.).
- Toute régularisation homogène de degré arbitraire.
- Des décompositions de rang faible matricielles et tensorielles (NMF, CPD, Tucker, etc.).

Proposition

Les solutions du problème explicite

$$\arg \min_{\forall i \leq n, X_i \in \mathbb{R}^{m_i \times r}} f(\{X_i\}_{i \leq n}) + \sum_{i=1}^n \mu_i \sum_{q=1}^r g_i(X_i[:, q])$$

sont essentiellement identiques à celles du problème implicite

$$\arg \min_{\forall i \leq n, X_i \in \mathbb{R}^{m_i \times r}} f(\{X_i\}_{i \leq n}) + \tilde{\mu} \sum_{q=1}^r \left(\prod_{i=1}^n g_i(X_i[:, q])^{\frac{1}{p_i}} \right)^{\frac{1}{\sum_{i=1}^n \frac{1}{p_i}}}.$$

où p_i est le degré d'homogénéité de g_i et $\tilde{\mu}$ dépend explicitement de μ_i .

Contributions scientifiques

Théorie

1. **Identifiabilité** : C. & Gillis (SIMODS 2019), C. et al. (LVA/ICA 2017)
2. **Caractérisation des solutions** : C. & Leplat (SIMODS 2025)
3. **Information auxiliaire** : C. & Gillis (IEEE TSP & TGRSL 2018), C. (Applied Mathematics and Statistics 2022), Kervazo et al. (EUSIPCO 2024)

Optimisation numérique: comment calculer les LRA

1. **Rapidité des algorithmes**: Nadisic et al. (ICASSP 2020), Pham et al. (TMLR 2026)
2. **Flexibilité**: Schenker et al. (IEEE JSTSP 2020), Roald et al. (SIMODS 2022)

Applications spécifiques


1. **Imagerie hyperspectrale microscopique** : Harriga et al. (EUSIPCO 2024), Carreda et al. (Biomedical Optics Express 2023)
2. **Informatique musicale**: Marmoret et al. (ISMIR 2020), Wu et al. (SMC 2022), Marmoret et al. (TISMIR 2023)

Zoom sur une contribution: Transcription automatique de musique

avec Axel Marmoret (MCF, IMT Atlantique, ancien doctorant)

et Haoran Wu (Syneron Technology (Chine), ancien stagiaire de master)


Transcription automatique ?



- Peut se faire “à la main”.
- L’état de l’art actuel est réalisé par des réseaux de neurones entraînés de façon supervisée.
[Hawthorne et al. 2018, Kong et al. 2020, Bittner et al. 2022]
- Notre travail est de montrer que l’on peut atteindre des performances comparables avec des méthodes faiblement supervisées, basées sur la NMF.

Notes isolées et séparation de sources



Analyse temps-fréquence d'un A4 (la milieu de clavier) joué au piano.





NMF-KL d'un enregistrement de piano



NMF-KL d'un extrait simple (vert)




NMF-KL d'un extrait complexe (rouge)




Une brique essentielle: la NMF convolutive

$$M = \sum_{q=1}^r \sum_{\tau=0}^{T-1} W[f, \tau, q] H[q, t - \tau].$$

- Les templates fréquentiels dépendent aussi du temps (modélisation de l'attaque et de la décroissance des notes).
- Proposé par [Smaragdis, 2006], algorithme efficace par [Fagot et al., 2019].



Notre contribution: NMF convolutive semi-supervisée



Idée: apprentissage semi-supervisé

Apprendre les templates fréquentiels sur des notes isolées (dataset MAPS) par des CNMF de rang 1.

Des résultats prometteurs...

- Pour chaque piano (EN1, EN2, AkB1, AkB2, AkC, AkS), on apprend les templates fréquentiels sur des notes isolées (dataset MAPS [Emiya et al. 2010]) par des CNMF de rang 1.
- Puis on calcule les activations temporelles sur un morceau de musique (dataset MAPS) par une CNMF.
- On effectue un seuillage sur les activations temporelles.

Méthode	τ	EN1	EN2	AkB1	AkB2	AkC	AkS	Sp	St
CNMF	5	82	74	90	80	87	84	86	81
	10	88	80	95	90	94	90	93	89
	20	85	78	95	90	94	89	92	89
AD*	—	82	69	68	73	61	69	66	70
DNN	—	89	77	98	95	98	87	97	95

Tableau : Performances en F mesure de CNMF, AD et du réseau profond de ByteDance. Tolérance de 50 ms. AD: [Cheng et al. 2016], DNN par ByteDance [Kong et al. 2020].

...mais des problèmes pour généraliser

Pianos	AkC	EN1	EN2	AkB1	AkB2	AkS	Sp	St
Entraînement sur AkC	94	.	74	77	77	70	74	77
Entraînement sur EN1	.	88	76	67	68	69	67	69

Tableau : Scores de transcription pour CNMF, avec un décalage entre les données d'apprentissage et de test.

Retour aux contributions scientifiques

Théorie

1. **Identifiabilité** : C. & Gillis (SIMODS 2019), C. et al. (LVA/ICA 2017)
2. **Caractérisation des solutions** : C. & Leplat (SIMODS 2025)
3. **Information auxiliaire** : C. & Gillis (IEEE TSP & TGRSL 2018), C. (Applied Mathematics and Statistics 2022), Kervazo et al. (EUSIPCO 2024)

Optimisation numérique: comment calculer les LRA

1. **Rapidité des algorithmes**: Nadisic et al. (ICASSP 2020), Pham et al. (TMLR 2026)
2. **Flexibilité**: Schenker et al. (IEEE JSTSP 2020), Roald et al. (SIMODS 2022)

Applications spécifiques

1. **Imagerie hyperspectrale microscopique** : Harriga et al. (EUSIPCO 2024), Carreda et al. (Biomedical Optics Express 2023)
2. **Informatique musicale**: Marmoret et al. (ISMIR 2020), Wu et al. (SMC 2022), Marmoret et al. (TISMIR 2023)

Perspectives de recherche

La divergence KL en traitement du signal

Pour un vecteur observé $y \in \mathbb{R}^d$ fixé, on pose

$$D_{\text{KL}}(y, x) = \sum_{i=1}^d y_i \log\left(\frac{y_i}{x_i}\right) + x_i - y_i, \quad x \in \mathbb{R}_{++}^d.$$


- Fonction de coût pour les données issues du comptage
 - Comptage de photon (tomographie, caméra médicales, astronomie...)
 - Comptage de mots dans des textes (topic modeling)
- Adaptés aux données à fortes dynamiques (spectrogrammes)

Important

Ne se réduit pas à une distance ℓ_2 si on compte peu d'objets, ou si les données sont très creuses.

Géométrie de la divergence de KL en dimension 1

$$D_{\text{KL}}(y, x) = y \log\left(\frac{y}{x}\right) + x - y, \quad x \in \mathbb{R}_{++}^d.$$



Important

La divergence KL est une fonction difficile à optimiser:

- son gradient est non lisse (Lipschitz).
- elle n'est pas fortement convexe et pas coercive (si présence de zéros).

Pourquoi étudier l'optimisation de modèles rLRA + KL ?

- Les algorithmes de régression avec une fonction de perte KL sont souvent indisponibles ou peu performants.
 - Par exemple la régression TV avec une perte KL a été étudiée seulement récemment [Maxim et al. 2023]

$$\arg \min_{h \geq 0} \mathcal{D}_{KL}(m, Wh) + \lambda \|h\|_{TV}.$$

- Les recherches actuelles se concentrent sur des l'utilisation de divergence Bregman, sachant que $\mathcal{D}_{KL}$ est de gradient lisse dans la géométrie induite par l'entropie de Burg [Bauschke et al. 2017].
- l'état de l'art **non régularisé** est dominé par MLEM/MU et ses variantes [Lucy 1974, Dempster 1977].

$$h^{(k+1)} = h^{(k)} * \frac{W^T \left(\frac{m}{Wh^{(k)}} \right)}{W^T \mathbf{1}}$$

Burg vs MLEM en régression KL

Hypothèse de travail


Il est possible de construire des algorithmes plus rapides que MLEM, et de les adapter pour des régularisations complexes.

- Avec **Damien Lesens** et Bora Ucar (LIP), nous sommes en train de montrer que
 - MLEM est toujours plus proche du coût que Burg,
 - MLEM est la meilleure majorante séparable de KL.

Idées



- Proposer des approximations locales (gradient préconditionné, Newton)
- S'inspirer de littératures voisines (points intérieurs, programmation linéaire)

Programme de recherche



Perspective 1 — benchmark et logiciel

- Pour NN-KL et NMF-KL, il manque encore une culture du **benchmark**.
- Une priorité est donc de construire :
 - un benchmark reproductible,
 - une liste d'algorithmes/implémentations de référence,
 - des jeux de données ouverts pour effectuer les évaluations,
 - un article de survey sur NN-KL et NMF-KL.



Perspective 2 — nouveaux outils d'optimisation

- NN-KL, des directions prometteuses :
 1. des approximations locales d'ordre deux plus serrés.
 2. l'exploitation du lien avec la **programmation linéaire**, surtout en données creuses.
- NMF-KL: explorer également les algorithmes non-alternés [Fagot et al. 2019]
- Objectif à long terme : des méthodes à la fois **rapides et bien comprises**.

En collaboration avec Mai Quyen Pham (IMT Atlantique, Brest) et Damien Lesens et Bora Ucar (LIP, Lyon)

Perspective 3 — Problèmes inverses en imagerie computationnelle

- Terrain d'application immédiat : **imagerie spectrale single-pixel**.
- Question méthodologique centrale : **quand faut-il vraiment une méthode dédiée KL ?**
 - en fonction du modèle d'acquisition
 - en fonction du niveau de bruit Poisson vs Gaussien


Je souhaite explorer notamment les résultats autour des transformations de réduction de variance (type [Anscombe, 1948, Foy 2011]).

- Développer des outils basés apprentissage profond, en lien avec la thèse de **Séréna Hariga**.
 - Thèse de Guilhem Dupuis à partir de octobre 2026 avec Valentin Debarnot.

Collaborations: en local à CREATIS + ICJ (Nicolas Ducros, Voichita Maxim, Elie Bretin, Valentin Debarnot...) et à l'international.

Perspective 4 - Transcription automatique avec NMF-KL et apprentissage profond

1. Utiliser un algorithme déroulé pour entraîner une NMF-KL convolutive.
2. Se baser sur les travaux de Magenta pour proposer un modèle hybride non-supervisé [Engel et al. 2020].



Conclusion

L'avenir des rLRA ?

+

- Des méthodes non-supervisés interprétables.
- Des garanties théoriques assez bien établies.
- Une modélisation physique au coeur des modèles.
- L'intérêt scientifique du travail sur l'optimisation numérique.

—

- Les performances état de l'art sont obtenues par des méthodes non-interprétables (réseaux profonds).
- Les méthodes non-supervisées sont souvent trop lentes pour être utilisées dans des applications temps réel.

Pour l'avenir, les rLRA pourront

- être utilisés comme **briques de construction** dans des modèles hybrides, combinant interprétabilité et performance.
- servir de baselines pour l'évaluations de modèles boîte noire.

Merci pour votre attention

Résumé des contributions scientifiques

Théorie

1. **Identifiabilité** : C. & Gillis (SIMODS 2019), C. et al. (LVA/ICA 2017)
2. **Caractérisation des solutions** : C. & Leplat (SIMODS 2025)
3. **Information auxiliaire** : C. & Gillis (IEEE TSP & TGRSL 2018), C. (Applied Mathematics and Statistics 2022), Kervazo et al. (EUSIPCO 2024)

Optimisation numérique: comment calculer les LRA

1. **Rapidité des algorithmes**: Nadisic et al. (ICASSP 2020), Pham et al. (TMLR 2026)
2. **Flexibilité**: Schenker et al. (IEEE JSTSP 2020), Roald et al. (SIMODS 2022)


Applications spécifiques

1. **Imagerie hyperspectrale microscopique** : Harriga et al. (EUSIPCO 2024), Carreda et al. (Biomedical Optics Express 2023)
2. **Informatique musicale**: Marmoret et al. (ISMIR 2020), Wu et al. (SMC 2022), Marmoret et al. (TISMIR 2023)

Backup

KL-div 2D


Courbes de niveau de la divergence de KL — le minimum est atteint en $x = y$





NMF, modèle géométrique

NMF exacte

$$M = WH^T$$



Spectre et oeil humain




source: <http://hyperphysics.phy-astr.gsu.edu/>

Autres travaux

Dictionary-based LRA


$$\min_{B \in \Omega_B, X \in \Omega_X, \|X[:,i]\|_0 \leq k \ \forall i \leq r} \|Y - DXB^T\|_F^2,$$

- Etude cas $k = 1$: unicité du problème matriciel, existence solution problème tensoriel, algorithme glouton.
- Etude du cas $k > 1$: algorithmes itératifs avec pénalisation ℓ_1 , étude théorique de l'algorithme glouton, conditions d'unicité.



LRA nonnégative avec contraintes ℓ_0

- Algorithme de Branch and Bound, application à la NMF séparable parcimonieuse.
- Parcimonie locale ou globale.



Deep Unrolling NMF

- Dérouler l'algorithme MU en NMF pour
 - l'accélérer (moins d'itérations),
 - apprendre à partir de données étiquetées.

$$\arg \min_{\theta} \sum_{i=1}^p \mathcal{L} (W_i^{gt}, H_i^{gt}, H_i(\theta), W_i(\theta)) \quad \text{such that} \quad \forall i \leq p, H_i(\theta), W_i(\theta) = \mathcal{A}(Y_i, \theta).$$

où l'algorithme $\mathcal{A}_i$ est un MU paramétrique (en loss ℓ_2):

$$W^{k+1} = W^k * \theta_W^k * \frac{Y H^k}{W^k H^{kT} H^k} \text{ et } H^{k+1} \leftarrow H^k * \theta_H^k * \frac{Y^T W^{k+1}}{H^{k+1} W^{kT} W^k}.$$

Décompositions couplées flexibles

- Framework ADMM flexible pour factorisations couplées tenseurs-matrices avec couplage linéaire.
- Adaptation pour le modèle PARAFAC2.

Exemple typique: CMTF régularisée.

$$\arg \min_{W, H, A, B, C} \|T - (A \otimes B \otimes C) \mathcal{I}_r\|_F^2 + \|M - WH^T\|_F^2 + g_H(H) + g_W(W) + g_A(A) + g_B(B) + g_C(C)$$

$$\mathcal{L}(A, W) = 0$$

- Utile en fusion de données en imagerie spectrale, métabolomique, imagerie médicale, etc.

Algorithme mSOM pour la NMF

- Idée: utiliser le fait pour une matrice symétrique $\mathbf{B}$ nonnégative, pour tout vector positif $\mathbf{u}$,

[Math Processing Error]


- On a alors une façon de construire une approximation quadratique d'un coût (ℓ_2 , β -div).
 - Pas une majoration hors cas ℓ_2 ,
 - majorisation de la Hessienne dans tous les cas.

Formule de mise à jour ($\mathbf{u} = 1$, optimal):

[Math Processing Error]





- Conditions de convergence
 - globale en $\ell - 2$,
 - locale en β -div, $\beta \geq 1$.

LRA en imagerie hyperspectrale




crédits: S. Hariga, N. Ducros et L. Mahieu-Williams

LRA en imagerie hyperspectrale — résultats



Estimation de la structure musicale



Burg vs MU

```

1 from matplotlib.pyplot import f
2 import numpy as np
3
4 # Hyperparameters
5 m, n = 100, 20 # number of samples and features
6 alpha = 100 # Poisson signal level
7
8 hgt = np.maximum(np.random.randn(n), 0)
9 W = np.random.rand(m, n)
10 y = np.random.poisson(alpha * W @ hgt)
11
12 def loss(h): # KL divergence
13     return np.sum(W@h-y) + np.sum(y * np.log((y+1e-10)/(W
14
15 def MU(y, W, h, itermax=1000, epsilon=1e-10):
16     Wtsum = W.T @ np.ones_like(y) # suboptimal but ok
17     hout = np.copy(h)
18     loss_val = [loss(hout)]
19     for i in range(itermax):
20         hout = np.maximum(epsilon, hout * (W.T @ (y / (W
21         loss_val.append(loss(hout))
22     return hout, loss_val
23
24 def BurgMU(y, W, h, itermax=1000, epsilon=1e-10): # NoL
25     Wtsum = W.T @ np.ones_like(y)
26     lamb = 1/2/np.sum(y)
27     hout = np.copy(h)
28     loss_val = [loss(hout)]
29     for i in range(itermax):
30         hout = np.maximum(epsilon, hout / (1 + lamb * h

```

Final loss MU: 45.853452716156845, Burg MU:
70.32802341548123
Estimation error MU: 0.06484584930114509, Burg MU:
0.10753978840794699

